

Human OS

Zasady, których nie da się ominąć — bo są wykonywane,
nie deklarowane

Dokument przeglądowy dla osób decyzyjnych, partnerów i zespołów, które rozważają oparcie własnego produktu na Human OS. Bez żargonu, za to konkretnie: co to jest, co już działa, czego jeszcze nie ma i na jakich zasadach można z tego korzystać.

wersja 0.9.0

status: BETA

sierpień 2026

Aplikacje

Integracje i Hub

Silnik

Specyfikacja

Konstytucja

każda warstwa niżej musi mieścić się w regułach warstwy wyżej

Human OS w jednym akapicie

Jeśli miałbyś przeczytać tylko jedną stronę, to tę

Human OS to spisany zestaw zasad, jak oprogramowanie może traktować człowieka — oraz działający silnik, który sprawdza każde zaplanowane działanie wobec tych zasad, zanim ono nastąpi. Zasady nie są dodatkiem do produktu; są bramką, przez którą produkt musi przejść.

1 To nie system operacyjny

Mimo nazwy — warstwa reguł do wbudowania w istniejący produkt.

2 To nie gotowy produkt

Wersja beta. Nie nadaje się dziś do wdrożenia produkcyjnego.

3 Cel jest nietypowy

Ma być coraz mniej potrzebny, im samodzielniejszy użytkownik.

Trzy zdania, które warto zapamiętać

Reguła zapisana w dokumencie jest deklaracją. Reguła zapisana w silniku jest warunkiem.

Odmowa systemu to poprawna odpowiedź, a nie awaria.

Możliwość odejścia z całym dorobkiem jest częścią umowy, nie uprzejmością.

Dokument nie zawiera prognoz rynkowych ani danych finansowych — nie ma dla nich podstaw w repozytorium.

Problem, który wszyscy znamy

Nie chodzi o złe intencje twórców oprogramowania, tylko o to, co jest mierzone



Decyzje przesuwają się do systemu

Coraz więcej drobnych wyborów — co przeczytasz, co zobaczysz, kiedy przerwiesz pracę — podejmuje algorytm. Każdy z osobna jest nieszkodliwy. Razem układają się w czyjś scenariusz dnia.



Zasady etyczne żyją osobno od kodu

Deklaracje o odpowiedzialnej technologii zwykle są dokumentem PDF, a nie warunkiem, który musi spełnić konkretne żądanie w konkretnym momencie. Nikt ich nie egzekwuje w czasie działania.



Wyjście bywa teoretyczne

Eksport danych często oznacza worek plików bez kontekstu, bez historii i bez powodów, dla których system podjął takie, a nie inne decyzje. Formalnie można odejść. Praktycznie — trudno.

To opis jakościowy. Świadomie nie podajemy tu statystyk — nie mamy własnych badań, na które moglibyśmy się powołać.

Pomysł: reguły, które da się wykonać

Ta sama zmiana, którą przeszły kiedyś testy jednostkowe i kontrola wersji

Weź zasady, które zwykle zostają na poziomie deklaracji — autonomia człowieka, świadoma zgoda, odwracalność, prawo wyjścia — i zapisz je w formie, którą maszyna potrafi sprawdzić przed wykonaniem działania.

Od tego momentu „system nie powinien tego robić” przestaje być opinią, a staje się warunkiem, którego niespełnienie zatrzymuje działanie — i zostawia po sobie ślad.

ZWYKLE

zasady w dokumencie

zgodność sprawdzana po fakcie

„zaufaj nam”

TUTAJ

zasady w silniku

warunek przed wykonaniem

sprawdź sam — kod jest otwarty

Nazwa własna tego mechanizmu w projekcie to Proof Kernel — dalej opisujemy go po ludzku, bez kodów.

Co z tego ma człowiek

Cztery rzeczy, które użytkownik odczuwa w praktyce, a nie tylko czyta w regulaminie



Wie, skąd system coś o nim wie

Przy każdym zapisie widać, czy to jego własne słowa, obserwacja systemu, czy tylko domysł — razem z cytatem i historią zmian.



Nie jest oceniany rankingiem

System nie porządkuje ludzi i nie sprzedaje pozycji w rekomendacjach. Gdy dane są sprzeczne, mówi „wstrzymuję się” zamiast zgadywać.



Może zatrzymać wszystko

Zestaw trybów awaryjnych — od zamrożenia po odcięcie — działa bez modelu AI i bez sieci, a żaden automat nie może ich wyłączyć.



Może odejść z całym dorobkiem

Eksport obejmuje dane, powiązania, historię wersji i ślad decyzji — w otwartym formacie, nie w worku plików.

Co z tego ma organizacja

Co zyskuje zespół, który buduje produkt na tej warstwie

1 **Polityka jako dane, nie jako slajd**

Reguły są zapisane w plikach, które czyta silnik. Zmiana reguły jest zmianą w repozytorium — z historią, autorem i przeglądem.

2 **Ślad, który da się pokazać**

Każde wykonane działanie zostawia poświadczenie i wpis w dzienniku spiętym łańcuchem skrótów. Manipulacja przy historii jest wykrywalna.

3 **Gotowe testy zgodności**

Dziewięć testów konstytucyjnych i zestaw testów automatycznych są częścią repozytorium — nie trzeba wymyślać własnego rozumienia zgodności.


4 **Mniejsze ryzyko sporu o dane**

Zgoda ma cel, zakres i czas; wyjście jest zaprojektowane od początku. To ułatwia wykazanie, jak system zachował się w konkretnej sprawie.

To nie jest opinia prawna ani deklaracja zgodności z konkretną regulacją. Human OS dostarcza mechanizmy i dowody, nie certyfikaty.

Jak to działa — widok z góry

Droga jednego żądania: od prośby człowieka do zapisanego śladu



Odmowa na dowolnym etapie jest normalnym wynikiem, nie błędem.

Gdy któraś brama nie przepuści żądania, kolejne etapy w ogóle się nie uruchamiają — nic nie zostaje wykonane ani zapisane, a człowiek dostaje informację, czego zabrakło i dlaczego.

Krok 1: kto pyta i na co ma zgodę

Pięć pytań, na które trzeba odpowiedzieć, zanim cokolwiek się wydarzy

- 1 Tożsamość** Czy żądanie pochodzi od tej osoby, za którą się podaje?
- 2 Rola** W jakiej roli występuje: właściciela danych, opiekuna, usługi, automatu? Rola to nie to samo co tożsamość.
- 3 Zgoda** Czy zgoda obejmuje właśnie te dane, w tym celu i w tym czasie? Zgoda ogólna nie wystarcza.
- 4 Kontekst** Jaki jest cel, budżet działania i warunki przerwania? Kontekst jest zamrażany, żeby dało się go później odtworzyć.
- 5 Dane sprawy** Których konkretnych obiektów dotyczy żądanie i czy w ogóle istnieją?

Kolejność ma znaczenie: pytanie o zgodę pada zanim system sięgnie po jakiekolwiek dane, a nie po fakcie.

Krok 2: dziewięć pytań kontrolnych

Tak brzmią testy zasad, gdy przetłumaczyć je na zwykły język

1

Czy człowiek pozostaje autorem tej decyzji?

2

Czy działanie nie zawęży jego samodzielności?

3

Czy tworzy coś, czy tylko konsumuje uwagę?

4

Czy nie wyciąga z niego wartości bez zwrotu?

5

Czy jest na to świadoma, konkretna zgoda?

6

Czy da się to cofnąć?

7

Czy nie uzależnia od rozwiązań, które szkodzą?

8

Czy dane zostają przenośne i da się odejść?

9

Czy ograniczenia są powiedziane wprost?

Każde pytanie ma w kodzie własny numer i własny skutek odmowy — powyżej podane są ich znaczenia, nie identyfikatory.

Krok 3: sześć możliwych odpowiedzi

System nie ma trybu „jakoś to zrobię” — każde żądanie kończy się jednym z sześciu wyników

Zgoda

Można wykonać bez zastrzeżeń.

Zgoda z ograniczeniem

Można, ale w węższej formie — na przykład jako szkic do redakcji, nie gotowa decyzja.

Potrzebna zgoda

Brakuje świadomej zgody na ten konkretny zakres i cel.

Decyzja należy do człowieka

Sprawa przekracza to, co system może rozstrzygnąć za kogoś.

Do przeprojektowania

Sposób wykonania łamie zasadę — trzeba zmienić projekt działania, nie prosić o zgodę.

Naruszenie zasad

Działania tego rodzaju nie wykonuje się w ogóle.

Kiedy system mówi: nie wiem

Wstrzymanie się jest osobnym, przewidzianym wynikiem — nie awarią i nie ciszą

Doradca, który zawsze ma odpowiedź, jest podejrzany. Gdy dane są sprzeczne, celu nie da się ustalić, ryzyko jest zbyt duże albo sprawa wykracza poza kompetencje systemu, Human OS nie wybiera wariantu z najwyższą punktacją. Nazywa powód i oddaje decyzję człowiekowi.

Powodów wstrzymania się jest osiem i każdy ma nazwę. To nie jest ozdobnik: nazwany powód można pokazać użytkownikowi, przetestować i zakwestionować.

brak jasnego celu

za mało danych

konflikt wartości

sprzeczne przesłanki

nie da się tego monitorować

zbyt duże ryzyko

poza kompetencją systemu

podejrzanie kryzysu

Osobno od wstrzymania się istnieje eskalacja: sprawa wraca do człowieka lub do opiekuna, zamiast zostać rozstrzygnięta automatycznie.

Co system o tobie wie

Trzy rodzaje zapisów, które nigdy się ze sobą nie mieszają

1

Powiedziałeś to sam

Twoje własne słowa. Tylko ty możesz je zmienić.

2

System to zauważył

Wzorzec w danych, które mu powierzyłeś — podany z zaznaczeniem, że to obserwacja.

3

System się domyśla

Hipoteza. Musi mieć wskazane przesłanki i nigdy nie jest podawana dalej jak fakt.



Poprawka nie kasuje historii

Zmiana tworzy nową wersję, a poprzednia zostaje widoczna wraz z powodem zmiany.



Odrzucenie to nie usunięcie

Zakwestionowany zapis dostaje status spornego — nie znika, ale i nie jest już używany jak fakt.



Zawsze można spytać „skąd to wiesz”

System pokazuje źródło, autora, poziom pewności i całą historię danego zapisu.



Sprzeczność zostaje sprzecznością

Napięcie między zapisami jest zachowane jako sygnał; rozstrzyga je wyłącznie osoba, której dotyczy.

Silnik nie rozpoznaje treści rozmowy samodzielnie — wskazanie, co jest kandydatem na zapis, należy do aplikacji i do człowieka.

Hamulec bezpieczeństwa

Siedem trybów awaryjnych, z których człowiek może skorzystać w każdej chwili

Tryb bezpieczny

ogranicza działanie do niezbędnego minimum

auto

Tylko odczyt

system przestaje cokolwiek zmieniać

auto

Zamrożenie

wskazany obszar zostaje wstrzymany

auto

Odcięcie

zerwanie połączenia z zewnętrzną reprezentacją

auto

Eksport

wydanie pełnej, przenośnej paczki danych

ręczny

Cofnięcie

powrót do wcześniejszego stanu z zachowaniem historii

ręczny

Odbudowa

odtworzenie środowiska po poważnej awarii — najpoważniejszy z trybów

dwa klucze

Automat nie może tego użyć

Agenci i usługi dostają odmowę, a sama próba zostaje zapisana.

Nie ma czego wyłączyć

Nie istnieje funkcja zmieniająca politykę ani czyszcząca dziennik audytu.

Działa bez AI i bez sieci

Warstwa awaryjna nie zależy od modelu ani od usług zewnętrznych.

Tryby ochronne mogą włączyć się samoczynnie, ale zawsze z powiadomieniem właściciela i zawsze są przez niego odwracalne.

Wyjście bez utraty dorobku

Jeśli odejście jest kosztowne, cała reszta obietnic traci znaczenie

Co zawiera paczka wyjściowa

- ✓ **Dane i powiązania**
w otwartym formacie, czytelnym bez tego systemu
- ✓ **Metadane i rejestr zmian**
co, kiedy i przez kogo było zmieniane
- ✓ **Historia wersji wycofanych**
nic nie znika po cichu — stare wersje zostają oznaczone
- ✓ **Ślad audytowy**
na jakiej podstawie system podejmował decyzje

Dlaczego to jest w centrum, a nie w opcjach

Kosztowne wyjście zamienia obietnicę samodzielności w pułapkę — niezależnie od tego, jak dobre są intencje twórców. Dlatego przenośność i możliwość odejścia mają w Human OS własny test kontrolny i własną zasadę w konstytucji, a każda zmiana w projekcie musi odpowiedzieć, czy ich nie pogarsza.

Z czego to się składa

Pięć warstw i jasny podział: co jest dokumentem, a co działającym kodem

Konstytucja

Zasady, prawa użytkownika, skala ryzyka, zakazy. Dokument nadrzędny.

dokument

Specyfikacja i protokół

Przenośne kontrakty i podpisane komunikaty między częściami systemu.

dokument + kod

Silnik

Bramy, testy zasad, tryby awaryjne, dzienniki i eksport.

kod

Integracje i Hub

Kierowanie komunikatów, sprawdzanie zgody, poświadczenia.

kod + projekt

Aplikacje

Konsola reguł i prototyp aplikacji osobistej. Bez własnych reguł.

prototypy

Zasada porządkująca: żadna warstwa niżej nie może po cichu zmienić reguły ustalonej wyżej.

Czego nie ma w tym repozytorium

Kod, o którym mowa, jest częścią większego przedsięwzięcia — nie jego całością

Warstwy modelu człowieka i wiedzy

Model człowieka, mapa wiedzy, profil rozwojowy i silnik decyzji mają pełne opisy projektowe; w kodzie istnieją na razie wybrane fragmenty.

Silnik eksperymentów osobistych

Warstwa prowadzenia własnych, małych eksperymentów życiowych — opisana i rozpisana na decyzje, bez implementacji.

Hub i szersza wymiana danych

Kierowanie komunikatów między niezależnymi uczestnikami sieci jest dziś dokumentacją, nie działającą usługą.

Laboratorium i środowisko testowe

Piaskownica dla testerów z własnym interfejsem: zaprojektowana, prototyp interfejsu istnieje poza tym repozytorium.

Warstwa narracyjna i White Paper

Rozdział o technologii, która pamięta, komu ma służyć — w repozytorium jest jego pełna transkrypcja.

Zarządzanie i historia decyzji

Kilkadziesiąt zapisów decyzji projektowych, przeglądy założyciela i kolejka spraw odłożonych świadomie.

Mówimy o tym wprost, żeby nikt nie ocenił całego przedsięwzięcia wyłącznie po zawartości jednego repozytorium — w żadną ze stron.

Co działa dzisiaj

Stan faktyczny, policzony z repozytorium — bez zaokrągleń w górę

36

modułów silnika

166

testów automatycznych

9

testów zasad

67

**zapisanych decyzji
projektowych**

W KODZIE, PRZETESTOWANE

- ✓ pełna droga żądania: tożsamość, rola, zgoda, kontekst, dane, test zasad, wykonanie, ślad
- ✓ siedem trybów awaryjnych wraz z eksportem, cofnięciem i odbudową
- ✓ silnik decyzji z twardymi warunkami wstępnymi, wstrzymaniem się i eskalacją
- ✓ dziennik zdarzeń spięty łańcuchem skrótów, z możliwością sprawdzenia integralności
- ✓ model tego, co system wie o człowieku, wraz z historią zmian i poziomem pewności
- ✓ podpisywane komunikaty, rejestr tożsamości i kluczy, ochrona przed powtórzeniem żądania

Testy uruchamiane są automatycznie na trzech wersjach Pythona przy każdej zmianie w repozytorium.

Czego nie obiecujemy

Lista, którą zwykle znajduje się dopiero podczas wdrożenia — tutaj jest od razu

 Brak logowania i uprawnień	Nie ma mechanizmu uwierzytelniania użytkowników ani kontroli dostępu na poziomie wdrożeniowym.
 Brak szyfrowania danych na dysku	Dane w spoczynku nie są szyfrowane przez sam silnik.
 Brak niezależnego audytu	Przegląd zewnętrzny jeszcze się nie odbył. Obecne podpisy to mechanizm referencyjny, lokalny.
 Brak kalibracji na danych	Skale ryzyka i progi nie zostały sprawdzone na rzeczywistym użyciu.
 Część opisanych warstw bez kodu	Kilka warstw ma dopracowany projekt, ale nie ma jeszcze implementacji.
 Dwa równoległe słowniki pojęć	Niektóre nazwy obiektów i relacji istnieją w dwóch wersjach; ujednolicenie jest świadomie odłożone.

Wniosek jest prosty: to wersja do badań, prototypów i integracji testowych — nie do produkcji z prawdziwymi danymi osób.

Licencje, znaki, zarządzanie

Na jakich warunkach można z tego korzystać i jak wygląda wprowadzanie zmian

Kod

Apache 2.0

Wolno używać komercyjnie, modyfikować i rozprowadzać, z zachowaniem informacji o autorstwie.

Dokumentacja

CC BY 4.0

Wolno cytować i przetwarzać z podaniem źródła — dotyczy konstytucji i specyfikacji.

Nazwa i znaki

polityka robocza

Rozgałęzienia projektu są w porządku, ale nie powinny przedstawiać się jako oficjalny Human OS.

Zmiana zasad to osobna ścieżka

Poprawka w konstytucji nie przechodzi zwykłym trybem — wymaga wyższego progu akceptacji i zgody człowieka odpowiedzialnego za projekt.

Każda zmiana deklaruje wpływ

Zgłoszenie musi napisać, które zasady wspiera, które stawia pod ryzykiem, jakie ma ograniczenia i czy nie pogarsza możliwości wyjścia.

Błędy zgłasza się prywatnie

Osobny kanał bezpieczeństwa, opisany w repozytorium — nie przez publiczne zgłoszenie.

Polityka znaku towarowego jest deklaracją roboczą projektu, a nie opinią prawną.

Droga do wersji 1.0

Osiem etapów zamkniętych, jeden otwarty i wyraźnie opisany cel

Zamknięte: formalny rdzeń · specyfikacja czytelna dla maszyn · silnik reguł · trwały, audytowalny zapis · graf wiedzy i pochodzenie danych · granice działania agentów · symulacje scenariuszy · model człowieka i zgoda

Etap otwarty

Zgodność protokołu między niezależnymi wdrożeniami oraz przegląd bezpieczeństwa

Prace nad kolejnymi warstwami toczą się równolegle i nie zastępują tego etapu.

WARUNKI OGŁOSZENIA WERSJI 1.0

stabilna konstytucja i model obiektów

protokół z jasnym wersjonowaniem

opisane ścieżki migracji

udokumentowany przegląd bezpieczeństwa

pełna przenośność danych

mierzalna, sprawdzalna możliwość wyjścia

Dla kogo to jest

Trzy sytuacje, w których warto sięgnąć po Human OS już teraz

1

Zespół produktowy

Buduje asystenta lub narzędzie pracujące na danych osobistych i potrzebuje sprawdzalnej granicy tego, co wolno zrobić bez pytania.

Pierwszy krok

Zacznij od uruchomienia konsoli reguł na własnym przykładzie działania.

2

Organizacja i dział ryzyka

Musi pokazać, jak system zachował się w konkretnej sprawie i na jakiej podstawie — nie ogólnie, lecz co do zdarzenia.

Pierwszy krok

Przejrzyj mechanizm śladu, zgody zakresowej i eksportu.

3

Badacz lub instytucja

Pracuje nad odpowiedzialną technologią i szuka opisu, który da się przetestować, a nie tylko zacytować.

Pierwszy krok

Konstytucja, zapisy decyzji i testy zasad są otwarte i cytowalne.

Jedno kryterium, do którego wszystko wraca

System, który ma stawać się coraz mniej potrzebny.

Miarą powodzenia nie jest to, ile czasu ktoś spędza w produkcie, tylko ile samodzielności z niego wynosi. Wszystkie opisane wcześniej mechanizmy — bramy, testy zasad, wstrzymanie się, poprawki, hamulec awaryjny, eksport — służą temu jednemu kryterium.

github.com/dudsi101-svg/human-os

Gdzie zajrzeć najpierw

Konstytucja

zasady i prawa użytkownika

Przegląd bezpieczeństwa

co jest, a czego brakuje

Zasady współpracy

jak zgłaszać zmiany

Zapisy decyzji

dlaczego zbudowano to tak